

FatalityCheck: A Validated 32-Year Corpus of U.S. Mining Fatalities from MSHA Investigation Reports (1995-2026)

El corpus como recurso validado — data/methods paper — la cita base del ecosistema

Revista objetivo: Journal of Safety Research (Q2, Elsevier) · Data / methods paper

PUBLICABLE YA

Abstract tentativo (borrador de trabajo)

Presentamos FatalityCheck, un corpus longitudinal de 1,668 fatalidades mineras EE.UU. (1995-2026) construido registro a registro desde informes finales de investigación MSHA bajo 30 CFR Part 50, con procedencia documental por caso, resolución de Mine ID del 99.7% y un protocolo de correcciones trazable de 26 reglas formalizadas. La validación externa contra el sistema Part 50 alcanza $r=0.970$, $p=0.955$ y CCC de Lin= 0.967 , con balance anual exacto 2000-2026. Demostramos su utilidad reproduciendo 36 elementos publicados de 17 estudios (75% en concordancia aceptable o superior) y liberamos el recurso con exports abiertos.

Pregunta y contribución

¿Puede construirse un dataset de fatalidades mineras verificado contra fuentes primarias, con validación externa cuantificada y correcciones auditables? Contribución triple: (1) la serie más larga de la literatura — 32 años vs. máximo 24 en P1-P17; (2) primera validación estadística declarada de un corpus de este tipo (ningún paper del inventario reporta la suya); (3) infraestructura de reproducibilidad: cada registro enlaza a su informe MSHA, y cada corrección histórica quedó tipificada (Reglas 14-26: fecha-accidente vs. fecha-muerte, barrido bisectorial de duplicados, gemelos intersectoriales, colisiones de ID, etc.).

Datos y métodos

1,668 registros activos · 88 campos base (víctima, mina, operador, mecanismo, tarea canónica, respuesta a emergencia, chargeability) · fusión sellada por clave canónica año+mes+número · cuarentena 0 · total_errors: 0 en recálculo automático. Cadena de fuentes con fallback documentado: informe final MSHA → servidor legado arlweb (pre-2000) → búsqueda operador+fecha+estado → miningincidents.org (referencia definitiva post-chargebacks, Regla 17). Casos múltiples (Sago 2006, Upper Big Branch 2010) resueltos como evento-víctima. Registros SUPERSEDED/ANULADO conservados y filtrables — la historia editorial es parte del recurso.

Resultados ya disponibles

Validación fatal-vs-fatal (eliminando el artefacto de sesgo de letalidad): $r=0.970$ · $p=0.955$ · Lin CCC= 0.967 · concordancia categórica 93% · desviación de conteos $\pm 3\%$. Reproducción de 36 elementos de 17 papers: 27/36 ACCEPTABLE+ (75%), 18 EXCELENTES — el Informe Comparativo S498 (43 págs., autovalidado geométricamente) es de facto la sección de resultados. Quinquenio 1995-1999 cerrado con procedencia OFICIAL-informe; década 2011-2020 certificada sin una sola corrección; distribución estatal completa (WV 273 · KY 208 · TX 90).

Estructura propuesta y figuras candidatas

IMRaD + sección "Data Records" estilo Scientific Data. Fig.1 serie anual corpus vs Part 50 (dline ya existente) · Fig.2 mapa/barras por estado · Fig.3 diagrama de flujo de ingesta y fallback · Tabla 1 diccionario de los 88 campos · Tabla 2 los 6 tests de validación · Tabla 3 comparativa de alcance vs P1-P17 (años, n, validación declarada). Suplementario: CSV/JSON de exports + las 26 reglas como protocolo.

Qué falta y cronograma estimado

Solo redacción (insumos completos): manuscrito 2-3 semanas de sesiones · declaración de disponibilidad de datos (web + app Android operativas) · 3 registros 2026 y 3 de 2025 esperando informe final MSHA — se declaran como censura administrativa, no bloquean. Riesgo principal: revisor pidiendo cruce con NIOSH/BLS → se responde con la sección Part 50 y divergencias documentadas. Ruta rápida alternativa: Data in Brief (Elsevier) con el mismo paquete en formato corto.

How Reproducible Is the MSHA-Based Safety Literature? A Systematic Replication of 36 Published Elements Against a Verified Corpus

Replicación sistemática — el más original: no existe precedente en seguridad minera

Revista objetivo: Safety Science (Q1, Elsevier) · Replication / meta-research

PUBLICABLE YA

Abstract tentativo (borrador de trabajo)

La crisis de replicación no ha llegado formalmente a la investigación en seguridad minera: los estudios empíricos basados en datos MSHA se citan sin que nadie haya intentado reproducir sus tablas y figuras. Inventariamos 218 elementos de 17 estudios (2005–2025), identificamos 36 reproducibles con fuente exacta, y los replicamos desde un corpus verificado de 1,668 fatalidades aplicando seis tests de similitud por elemento. El 75% alcanza concordancia aceptable o superior; los restantes se resuelven con evidencia primaria en tres techos demostrados y cinco divergencias de constructo documentadas — incluyendo una tabla publicada con valores sintéticos "typical" y figuras citadas que no existen como serie. Proponemos la categoría DIVERGENCIA DOCUMENTADA como estándar para replications en el área.

Pregunta y contribución

¿Cuánto de la literatura MSHA se sostiene al re-derivarla desde datos verificados? Contribuciones: (1) primer ejercicio sistemático de replicación del área; (2) la categoría DIVERGENCIA DOCUMENTADA (púrpura #6B4E9B): constructos no equivalentes probados con el PDF del paper en mano — distinta de error y de manipulación, protege al autor replicado; (3) el diseño fatal-vs-fatal que eliminó el artefacto de letalidad y elevó los cuatro parámetros de validación a excelencia; (4) reproducibilidad de segundo orden: el estudio entero es un pipeline scriptado con auditor geométrico — el revisor puede re-correr el informe.

Datos y métodos

218 elementos inventariados → 36 con fuente exacta o techo PROBADO · 6 tests por elemento (Pearson r con p -valor, Spearman ρ , RMSE, MAE, MAPE, Δ Total) · escala EXCELENTE/BUENO/ACEPTABLE/PARCIAL pre-definida por umbrales de r · cuando el paper no publica la serie numérica se compara estructura y se declara en Procedencia · diligencia registrada: hasta tres operacionalizaciones probadas por elemento antes de declarar techo (p.ej. I-01: universo con-equipos, filtro causal, nombrada-contra-nombrada).

Resultados ya disponibles

EXC 18 · BUENO 3 · ACEPT 6 · PARCIAL 4 · DIVERGENCIA 5 = 27/36 (75%). Hallazgos meta-científicos concretos: Table 2 de P15 declara valores "typical" (sintéticos, no empíricos); las "Figs. 6–8" de Karra 2005 citadas como serie anual no existen en el paper (es un modelo de tasas Poisson/NB); el Miscellaneous=172 de Kecojevic es un cajón residual irreproducible por diseño; el criterio equipo-operado vs. equipo-primario certificado como diferencia metodológica con respaldo del campo oficial MINING_EQUIP. Evolución S411→S495: de 11 EXCELENTE nominales a 18 verificados — el rigor subió el resultado, no lo bajó.

Estructura propuesta y figuras candidatas

Intro (crisis de replicación → seguridad) · Métodos (inventario, criterios de reproducibilidad, tests) · Resultados por familia de paper · Discusión (taxonomía de causas de no-replicación: sintéticos, cajones residuales, constructos, ventanas). Fig.1 distribución de calificaciones · Fig.2 r por elemento ordenado · Fig.3 anatomía de una divergencia (caso P15) · Tabla maestra 36×6 tests. Suplementario: los 43 págs. del Informe S498 + scripts.

Qué falta y cronograma estimado

Redacción con encuadre constructivo ("límites de comparabilidad") — 3–4 semanas · cover letter anticipando sensibilidad de autores replicados · decisión ética: no se nombra "error" donde hay constructo distinto. Riesgo: revisor = autor replicado; defensa: evidencia primaria por divergencia y tono. Este paper cita al Paper 1 (el recurso) — conviene enviarlos escalonados.

Cognitive Bias Fingerprints in Accident Investigation: Coding 16 Bias Families Across 1,668 MSHA Fatality Reports

La capa de sesgos — flagship Q1 — condicional al estudio Kappa IRR

Revista objetivo: Safety Science (Q1, Elsevier) · Empírico / metodológico

CONDICIONAL: κ IRR

Abstract tentativo (borrador de trabajo)

Los informes de investigación de accidentes no solo describen causas: las construyen, y en esa construcción quedan huellas de sesgos cognitivos del proceso investigativo. Operacionalizamos 16 familias de sesgos (marco MAP) como disparadores textuales verificables y codificamos los 1,668 informes fatales MSHA 1995–2026 en doble capa: experta (100% del corpus) y automática con cita textual por activación (1,129 casos, ~2,450 activaciones citadas). La atribución mediada por la fórmula causal estándar ("the accident occurred because the operator did not...") y la presión temporal emergen como firmas dominantes y estables a través de cinco eras regulatorias. Reportamos fiabilidad inter-codificador (κ por familia) y publicamos el codebook completo.

Pregunta y contribución

¿Qué sesgos imprime el propio proceso investigativo en sus conclusiones, y son estables en 32 años? Nadie lo ha medido a escala: el precedente más cercano es Bellanca 2021 (NIOSH, P16) con 91 casos codificados a doble ciego — aquí son 1,668 con dos capas independientes y citas textuales por activación. Contribución metodológica: el COPILOTO S488 convierte constructos psicológicos en disparadores léxicos auditables (p.ej. E5 superioridad-por-experiencia = " ≥ 30 años de experiencia" + omisión de verificación propia; N1 reconstrucción narrativa = "no eyewitnesses"/"apparently"/"consensus").

Datos y métodos

Marco MAP-v1: 16 familias A–P en 187 columnas (Cat-B activaciones + Cat-A espejos estructurales) · capa v1 EXPERTA sobre el 100% del corpus (42 provisionales S485/S486 marcados para ratificación) · capa v2 AUTO-COPILOTO: 1,129 casos, ~2,450 activaciones B con cita y procedencia + ~460 espejos A (solo los 8 pares estructurales) · hoja MAP-v2 con ~2,890 filas caso|familia|cita|procedencia · piloto de codificación directa 10/10 casos con la frase-núcleo presente.

Resultados ya disponibles

O1 presión-temporal = sesgo dominante en las 5 eras regulatorias (robusto al cambio de formato de informe ~2015) · concordancia diccionario-vs-experto 52.6% (116 casos) — suficiente para triaje, insuficiente para verdad-terreno: justifica empíricamente el estándar humano · Jaccard v1-vs-v2 = 23.3%: las dos capas ven cosas distintas, argumento para la codificación dual · 8 familias nuevas operacionalizadas con honestidad de techos (A1/H1 = techo textual con 0 activaciones: el constructo no deja huella léxica en este género documental — hallazgo en sí mismo).

La puerta pendiente: protocolo Kappa IRR

★ Prerequisito no negociable para Q1: 2º codificador humano independiente con el COPILOTO (16 familias) · muestra diseñada: caso ancla CAI-2002-42 + 9 casos ALTA densidad + 10% estrato BAJA + los 42 provisionales + casos de familias B–N · meta $\kappa \geq 0.70$ por categoría (precedente P16) · si alguna familia queda bajo umbral: reportar, recalibrar codebook, repetir solo esa familia (iterativo estándar) · codebook publicado como material suplementario · ratificación de provisionales por el investigador principal. Insumo logístico: re-subir los RAR de informes de los casos muestreados.

Estructura propuesta y cronograma

Intro (sesgo en investigación de accidentes; hindsight/atribución) · Métodos (marco MAP, codebook, IRR) · Resultados (prevalencias, series por era, κ) · Discusión (implicancias para redacción de informes MSHA y formación de investigadores). Fig.1 heatmap familia $\times$ era · Fig.2 prevalencias con IC · Fig.3 κ por familia · Fig.4 anatomía de una activación citada. Cronograma: Kappa 2–3 semanas (depende del 2º codificador) + redacción 3–4 semanas. Es el paper que convierte a FatalityCheck de recurso en programa de investigación.

Three Decades of U.S. Mining Fatalities: Regulatory Eras, Contractor Burden, and the Intersectoral Twin Pattern (1995-2026)

Análisis epidemiológico propio sobre la serie limpia — bonus de alto rendimiento

Revista objetivo: AAP (Q1) o Resources Policy (Elsevier) · Empírico longitudinal

PUBLICABLE YA

Abstract tentativo (borrador de trabajo)

Analizamos 32 años de fatalidades mineras EE.UU. (1995-2026, $n=1,668$) sobre un corpus verificado registro a registro, examinando quiebres asociados a eras regulatorias (MINER Act 2006, revisiones de chargeability), la carga persistente de contratistas y un patrón de calidad de datos con implicancia de vigilancia: el "gemelo intersectorial", donde contratistas de carbón aparecen clasificados en el sector metal/no-metal por nombre de contratista en vez de operador de mina. A diferencia de estudios previos limitados a ventanas ≤ 24 años con costuras de fuente, la serie mantiene un instrumento único y cada punto atípico es auditable contra su informe primario.

Pregunta y contribución

¿Cómo cambian mecanismo, demografía y carga de contratistas a través de los quiebres regulatorios? Ventajas estructurales sobre P1-P17: mismo instrumento 32 años, sin costuras; capacidad de auditar cada outlier informe-en-mano; y el gemelo intersectorial como hallazgo inédito — un artefacto de clasificación oficial que distorsiona las estadísticas sectoriales y que solo un corpus reconciliado bisectorialmente puede detectar (confirmado en múltiples casos, Regla 16 de barrido dual).

Datos y métodos

Serie 1995-2026 con eras regulatorias como variable estructural · regresión segmentada / test de Chow sobre conteos anuales (y tasas si se ingieren denominadores) · estrato contratista vs. empleado directo · demografía: envejecimiento de víctimas y factor experiencia (≥ 30 años + omisión de verificación — puente con Paper 3) · mecanismos vía tarea canónica (correa 241 · continuous miner 225 · acarreo 149 · CAEX 122) · eventos múltiples correctamente resueltos (Sago 2006, UBB 2010) para no sesgar los quiebres.

Resultados ya disponibles

Nivel de contratistas 20.6% — calza con el rango 19-26% de Karra 2005, validación cruzada ya sellada en I-23 · caída sostenida post-2010 y meseta 2015-2026 visibles en la serie certificada (mín. 27 en 2016/2019 vs. 101 en 1995) · repunte relativo 2021-2023 (38/30/40) como candidato a quiebre post-pandemia · distribución estatal completa con concentración WV+KY = 29% del total · el quinquenio 1995-1999, antes hueco estructural, hoy con procedencia oficial: el análisis pre-MINER Act es ahora defendible.

Estructura propuesta y figuras candidatas

Intro (política minera y eras) · Métodos (corpus + modelos de quiebre) · Resultados (serie, quiebres, contratistas, gemelos, demografía) · Discusión (vigilancia y clasificación oficial). Fig.1 serie anual con eras sombreadas y quiebres estimados · Fig.2 proporción contratista por año con IC · Fig.3 diagrama del gemelo intersectorial (casos reales anonimizados) · Fig.4 pirámide edad x era · Tabla 1 mecanismos por era. Todo generable con el pipeline matplotlib existente.

Qué falta y cronograma estimado

Correr los modelos de quiebre (datos listos; 1 semana de sesiones) · ingesta opcional de denominadores horas-empleo Part 50 si se quieren tasas — si no, se declara el límite y se trabaja con conteos como hace la mitad de P1-P17 · lit review post-2022 · decisión de revista según ángulo: AAP (epidemiológico) vs. Resources Policy (política). Riesgo "un paper más de tendencias": neutralizado por gemelo intersectorial + trazabilidad + puente con la capa de sesgos. Redacción: 3 semanas.